

TP02-AI :

Partie 5 — Représentation Bag of Words :

- Que représente chaque colonne de la matrice ?

Chaque colonne représente un **mot unique** appartenant au vocabulaire global extrait de l'ensemble du corpus

- Quelles sont les limites du modèle Bag of Words ?

Matrice creuse - Aucun sens sémantique - Poids excessif des mots fréquents

- Que perd-on en supprimant l'ordre des mots ?

En supprimant l'ordre des mots, on perd : La syntaxe et la grammaire - Le contexte et le sens global - La gestion de la négation.

Partie 6 — Représentation TF-IDF :

- Quelle est la différence principale entre BoW et TF-IDF ?

- **Bag of Words (BoW)** mesure uniquement la **fréquence brute** (comptage) des mots dans chaque document.
- **TF (Term Frequency)** : Mesure la fréquence d'un mot dans un document donné.
- **IDF (Inverse Document Frequency)** : Réduit le poids des mots qui apparaissent fréquemment dans *tous* les documents du corpus.

- Pourquoi les mots très fréquents ont-ils souvent un poids faible ?

Parce que la composante **IDF** calcule l'inverse de la fréquence du mot dans l'ensemble du corpus.

- Donnez un exemple concret où TF-IDF serait plus utile que BoW.